Lenguaje Python

Cursada 2025

📖 Clase 4: Archivos (cont.)

- 🚐 Manejo de datos en archivos
- ⏰ Módulo datetime
- 🎠 Funciones mágicas en Jupyter

Lo visto en clase

> Abrir, modificar, crear archivos con el módulo **csv** y **json**

> Un programa puede estar formado por muchos módulos

🚐 Manejo de datos en archivos

Vamos a trabajar con archivos **csv** y probar algunas operaciones con los datos

In [ ]:
```
from pathlib import Path
import csv
```

In [ ]:
```
data_temp = Path("ejemplos") /"clase04_1"/ "files"/ "tas_climatology_annual-seasonal_
```

Vemos el contenido usando el container **with** si no usamos el container recuerden que se tiene que:

- abrir con open()
- cerrar con close() para evitar problemas con los archivos

Hay atajos de Jupyter que nos permiten conocer el contenido de directorios

In [ ]:
```
! ls 'ejemplos/clase04_1/files'
```

Con el caracter "!" indicamos que es un comando de linux y los intepreta para ejecutarlos en Jupyter.

In [ ]:
```
with  open(data_temp) as file_temp:
    csv_reader = csv.reader(file_temp, delimiter=',')
    for line in csv_reader:
        print(line)
    header, data = next(csv_reader), list(csv_reader)
```

- ¿Qué pasa con los datos en las variable *csv_reader* después de recorrer un vez?
- ¿Qué tipo de variable es *csv_reader*?

> Un **iterador** es un objeto que representa un flujo de datos.

Al abrir este flujo de datos, nos posicionamos en el primer ítem y luego, utilizando el método **next()** del iterador o al pasar la función incorporada **next()** vamos obteniendo los siguientes ítems del flujo. Este

proceso finaliza cuando no hay más datos disponibles.

Para poder trabajar con los datos tenemos que guardarlo en un variable que no sea iterador.

In [ ]:
```
with  open(data_temp) as file_temp:
    csv_reader = csv.reader(file_temp, delimiter=',')
    header, data = next(csv_reader), list(csv_reader)
```

👀 Conozcamos los datos

In [ ]:
```
print(header)
for line in data:
    print(line)
```

Nombres de las columnas

- (DJF): Diciembre, Enero, Febrero (Verano)
- (MAM): Marzo, Abril, Mayo (Otoño)
- (JJA): Junio, Julio, Agosto (Invierno)
- (SON): Setiembre, Octubre, Noviembre (Primavera)

Si queremos tener un diccionario para acceder a los datos de cada jurisdicción directamente, ¿qué estructura podemos usar?

In [ ]:
```
data ={}
with  open(data_temp) as file_temp:
    csv_reader = csv.DictReader(file_temp, delimiter=',')
    for row in csv_reader:
        print(row)
```

Recordemos que:

> **DictReader** permite crear un diccionario donde el nombre de las columnas son las **keys** el el valor de la celda son los **values**

In [ ]:
```
data =  {}
with  open(data_temp) as file_temp:
    csv_reader = csv.DictReader(file_temp, delimiter=',')

    for row in csv_reader:
        data[row['Región']] = dict(row)
data
```

🎊 Mejorando la estructura para facilitar el procesamiento

Recordemos la estructura del archivo:

```
['Región', 'Annual', 'DJF', 'MAM', 'JJA', 'SON']
['Argentina', '14.60', '20.55', '14.45', '8.42', '14.98']
```

In [ ]:
```
data ={}
with  open(data_temp) as file_temp:
    csv_reader = csv.reader(file_temp, delimiter=',')
    header = next(csv_reader)
    for row in csv_reader:
        data[row[0]] = row[1:]
```

In [ ]:
```
data
```

- La primera línea es la **anual**.
- Tener en cuenta esto cada vez que realizamos los cálculos.
- Empezar desde la segunda línea, o guardar los datos por separado.

In [ ]:
```
data ={}
anual = []
with  open(data_temp) as file_temp:
    csv_reader = csv.reader(file_temp, delimiter=',')
    header = next(csv_reader)
    anual = next(csv_reader)
    for row in csv_reader:
        data[row[0]] = row[1:]
```

In [ ]:
```
anual
```

🚨Desafío 1

> Queremos obtener la temperatura anual promedio mínima.

Recordemos el orden de los datos:

In [ ]:
```
header
```

- El diccionario **data** contiene desde el segundo elemento (temperaturas de las jurisdicciones.
- La **key** es la 'Región'.
- En la posición **0** de la lista de los valores asociados a cada **Región** es la temperatura que debemos recolectar para calcular el mínimo.

En el header vemos que **DJF** es la columna correspondiente:

In [ ]:
```
header[1:]
```

In [ ]:
```
min([data[temp][0] for temp in data])
```

¿Pero es esta la temperatura mínima?

Veamos los datos:

In [ ]:
```
for prov in data:
    print(data[prov][0])
```

Mirando rápido encontramos varias temperaturas más bajas que 10.01:

- 4.86
- 7.76

Convertir los valores

- El módulo **csv** considera como **str** los datos leídos.
- El valor que indicó es tomado con el orden alfabético.
- Para comparar numéricamente tenemos que convertilos a **float**.
- Podemos hacerlo al guardarlos en el diccionario .

In [ ]:
```
data ={}
anual = []
with  open(data_temp) as file_temp:
    csv_reader = csv.reader(file_temp, delimiter=',')
    header = next(csv_reader)
    anual = next(csv_reader)
    anual [1:] = [float(elem) for elem in anual[1:]]
    for row in csv_reader:
       data[row[0]] = [float(elem) for elem in row[1:]]
```

In [ ]:
```
data
```

Calculamos nuevamente la temperatura mínima anual:

In [ ]:
```
min([data[temp][0] for temp in data])
```

Ahora sí es correcto el valor.

Cálculos de eficiencia en Jupyter

- Jupyter nos permite medir tiempo de ejecución (nuestra computadora) de códigos cortos.
- **%timeit** calcula la ejecución de una línea.
- **%%timeit** calcula la ejecución de varias líneas.
- Ejecuta 7 veces el código y muestra las estadísticas.

In [ ]:
```
%timeit L= min([data[temp][0] for temp in data])
```

In [ ]:
```
%%timeit
minim = 999
for juri in data:
    if data[juri][0] < minim:
        minim = data[juri][0]
minim
```

✨ Atajos en Jupyter

Estando fuera del modo edición:

- ✅ a: agrega una celda arriba de donde estamos
- ✅ b: agrega una celda abajo de donde estamos
- ✅ dd: borra la celda actual
- ✅ m: convierte la celda en el formato markdown
- ✅ y: convierte la celda en el formato código

🚨 Desafío 2

> ¿Qué jurisdicciones tuvieron una temperatura menor que la promedio anual?

In [ ]:
```
anual
```

Recordemos que:

- ✅ **filter**: permite filtrar elementos de una secuencia
- ✅ **dict.items()**: me devuelve una lista con una tupla con las keys y los valores asociados

In [ ]:
```
list(filter( lambda prov: prov[1][0] > anual[1], data.items()))
```

🚧 Consigna 1 para practicar

- Encontrar las jurisdicciones con las temperaturas mínimas y máximas de cada estación.

📂 Ordenar los datos

Queremos ordenar los datos de forma descendente según los valores de las temperaturas de la estación Verano. Recordemos que:

- ✅ **sort**: es un método que permite ordenar una secuencia modificándola.
- ✅ **sorted**: es una función nos permite ordenar una secuencia indicando varias opciones para la acción sin modificar la secuencia original.

Las columnas de temperaturas que teníamos eran las siguientes:

In [ ]:
```
header
```

Recordemos que **DJF** es el **verano**

In [ ]:
```
data
```

data.items() contiene una tupla con los elementos:

(key, values)

El elmento **values** es una lista donde tiene en la posición 1 la temperatura del verano.

In [ ]:
```
dict(sorted(data.items(), key=lambda item: item[1][1], reverse=True))
```

Y la temperatura del invierno de forma ascendente:

In [ ]:
```
%timeit L = dict(sorted(data.items(), key=lambda item: item[1][2]))
```

📌 Ejemplo de paquetes en el IDE

📝Procesamiento de logs

- Trabajamos con el logs de los registros de Moodle.

In [ ]:
```
logs_file = 'logs_Python 2024_20240326-1737.csv'
dir_files = Path('ejemplos') / 'clase04_1' / 'files'
```

In [ ]:
```
with  open(dir_files / logs_file) as file_temp:
    csv_reader = csv.reader(file_temp, delimiter=',')
    header, data_logs = next(csv_reader), list(csv_reader)
```

🚨Desafío 3

> Encontrar los registros que tienen las IP que no son de la facultad.

In [ ]:
```
header
```

Para no procesar todos los datos, vamos a trabajar con las primeras 300 filas:

In [ ]:
```
for row in data_logs[:300]:
    if not row[6].startswith('163.10.'):
        print(row)
```

En la salida vemos que los nombres se repiten según la cantidad de veces que accedió cada persona. Podemos guardar los datos en una estructura sin repetición.

In [ ]:
```
header
```

In [ ]:
```
data_names = {}
for row in data_logs:
    if not row[1] in data_names:
        data_names[row[1]] = row
```

In [ ]:
```
data_names
```

Para no ver todos los datos podemos acceder de otra forma, y elegir ver los 5 primeros.

In [ ]:
```
for row in range(5):
    print(data_logs[row])
```

⏱️ Módulo datetime

Datetime es un módulo para trabajar con las fechas

- ⏩ Nos permite trabajar y realizar cálculos con el tiempo.
- ⏩ Documentación módulo **datetime**

Contiene varias clases para manejar fechas y tiempo:

- ✅ **date**: se utiliza para fechas pero no guarda hora, minutos ni segundos
- ✅ **time**: se utiliza para operar valores de tiempo al nivel de minutos a microsegundos
- ✅ **datetime**: contiene información de las fechas **date** y tiempo **time**

Algunas de la características que comparten estos objetos son:

- ⏩ Son **inmutables**.
- ⏩ Son **"hashable"**, es decir que se pueden usar como keys en un diccionario.

In [ ]:
```
from datetime import date
d1 = date(2024,3,26)
d1
```

In [ ]:
```
from datetime import time
t1 = time(11, 10, 9)
t1
```

🚨 **OJO** que existe el módulo **time** que tiene funcionalidades similares, en comparación con el submódulo de datetime, el módulo **time** tine un poco más de precisión el nivel de microsegundos y es recomendado de usar solo en sistemas operativos UNIX.

- **d1** es una fecha
- **t1** es una hora

Podemos combinarlos

In [ ]:
```
from datetime import datetime
my_datetime = datetime.combine(d1, t1)
my_datetime
```

Los objetos **date**, **time** y **datetime** pueden operar entre sí, se usan según lo que se necesite.

🕐¿Qué podemos realizar con la clase **datetime**?

¿Cómo podemos ver los métodos de una clase?

- ⏩ dir()
- ⏩ en Jupyter, el tab nos ayuda para autocompletar, donde nos marca cuáles son funciones y cuáles son variables de la clase

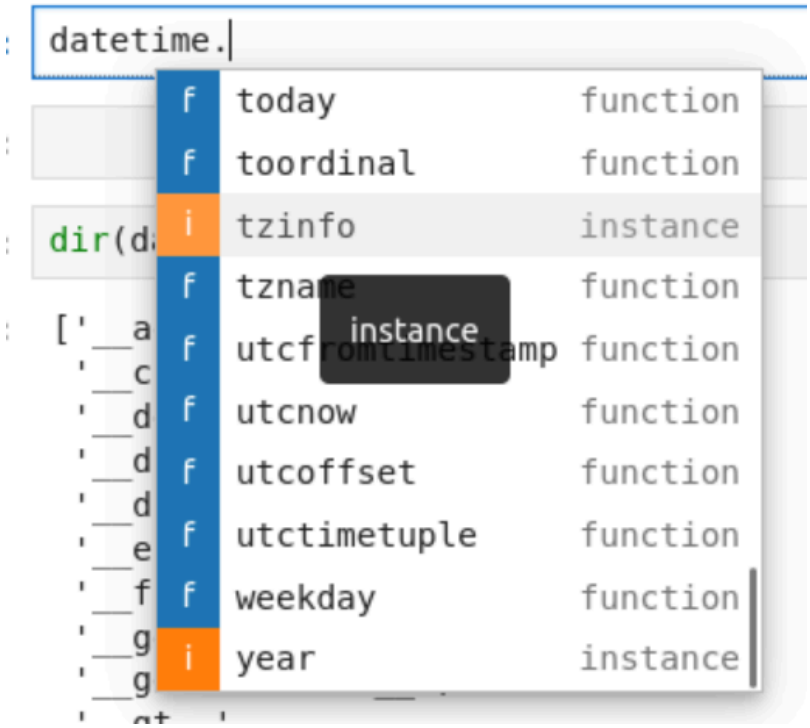

In [ ]:
```
datetime.today()
```

Al crear debemos especificar la información de tzinfo.

In [ ]:
```
from datetime import timezone
print(datetime.now(timezone.utc))
print(datetime.now(timezone.utc).tzinfo)
#en python 3.11
#datetime.now(datetime.timezone.utc)
```

Algunos de los métodos que pueden ser interesantes de **datetime.datetime**, para simplificar asumamos que los importamos:

`form datetime import datetime`

- ✅ **datetime.now():** nos da la fecha actual

- ✅ **datetime.timestamp(datetime.now()):** convierte la hora actual en el formato timestamp, que es utilizado para guardar fecha de forma única
- ✅ **datetime.strptime()**: convierte un string con el formato que le indicamos en un objeto *datetime*
- ✅ **date.strftime("%m/%d/%Y, %H:%M:%S")**: convierte un objeto *datetime* a un string
- ✅ **date.weekday()**: podemos saber el día de la semana de la fecha
- ✅ **date.hour**: podemos saber la hora

Los datos que se guardan en los **logs**, en general van acompañados de un **timestamp**, que es un número que representa el tiempo pasado desde 1/1/1970.

In [ ]:
```
my_timestamp = datetime.timestamp(datetime.now())
my_timestamp
```

Se puede guardar en ese formato o como un string, lo cual es más legible.

In [ ]:
```
my_log = datetime.fromtimestamp(my_timestamp)
```

In [ ]:
```
my_log.strftime("%m/%d/%Y, %H:%M:%S")
```

- **"%m/%d/%Y, %H:%M:%S"** le indica el formato que debe representarse la fecha, más adelante explicamos en detalle

🚨 Desafío 4

> Encontrar cuánto tiempo pasó desde el primer registro hasta el último.

Si recordamos cómo está almacenado el dato de las fechas en el archivo:

```
['26/03/24, 10:34:02', 'TOMAS PANELO', '-', 'Cuestionario: Autoevaluación 1 - Turno MAÑANA', 'Cuestionario', 'Módulo de curso visto', "The user with id '21520' viewed the 'quiz' activity with course module id '39686'.", 'web', '163.10.143.25']
```

La posición 0 contiene el string con la fecha, veamos cómo podemos convertir ese string en un objeto datetime.

In [ ]:
```
format = "%d/%m/%y, %H:%M:%S"
for row in range(20):
    print(datetime.strptime(data_logs[row][0], format))
```

El método **strptime()** permite convertir un **str** en un objeto datetime, pero primero debemos indicar el **formato** para que interprete el string:

```
format = "%d/%m/%y, %H:%M:%S"
```

La variable **format** es un string que tenemos que armar en función de cómo está guardada la fecha, esto varía según sea el caso.

Veamos qué operaciones se pueden realizar con las fechas que están guardadas. Como vimos esta información está en la primera posición, en formato **string**:

In [ ]:
```
date_str = data_logs[0][0]
date_str
```

Y para convertir a un objeto datetime usaremos el método **strptime**:

In [ ]:
```
my_date = datetime.strptime(data_logs[0][0], format)
my_date
```

Veamos otro ejemplo con otro formato.

In [ ]:
```
format = "%d/%m/%Y, %H:%M:%S"
date = datetime.strptime(data_logs[0][0], format)
date
```

¿Por qué creen que da error?

Da error porque el año especificado en la variable **format** (%Y) al ponerlo en mayúscula espera cuatro dígitos y en el archivo sólo tiene dos dígitos.

Veamos con un ejemplo con otro formato en el dato.

In [ ]:
```
date_oth = '26/03/2024, 17:36:54'
format = "%d/%m/%Y, %H:%M:%S"
date = datetime.strptime(date_oth, format)
date
```

En este caso al estar el año con 4 dígitos no hubo problema.

Volvamos con las fechas del archivo

In [ ]:
```
format = "%d/%m/%y, %H:%M:%S"
date = datetime.strptime(data_logs[0][0], format)
date
```

- Buscamos el último registro
- Recordemos que podemos obtener la longitud total con **len**

In [ ]:
```
len(data_logs)
```

In [ ]:
```
data_logs[len(data_logs)-1]
```

Calculamos las fechas de inicio y final del archivo de logs:

In [ ]:
```
date_start = datetime.strptime(data_logs[len(data_logs)-1][0], format)
date_start
```

In [ ]:
```
date_end = datetime.strptime(data_logs[0][0], format)
date_end
```

Y el tiempo que pasó entre ambas fechas:

In [ ]:
```
date_end - date_start
```

🚧 Consigna 2 para practicar

- Calcular la cantidad de registros que hay por cada día de la semana.

Recordemos que:

```
date_start.weekday()
```

nos permite acceder al día de la semana y el módulo Counter nos ayuda a encontrar las cantidades correspondientes.

- ¿Se animan a hacerlo con list comprehension?
- Los que quieran, pueden subir el código a su repositorio en GitHub y compartir el enlace a las

cuentas @clauBanchoff y @sofiamartin

Conociendo el entorno de Jupyter

Analice qué información nos brindan los siguientes comandos:

In [ ]:
```
%history
```

In [ ]:
```
who
```

In [ ]:
```
whos
```